

LAPORAN TEKNIS KOMPREHENSIF

DATA SCIENCE

**"DyslexiaLens: Pendeteksian Disleksia Berbasis Explainable AI pada Tulisan
Tangan Anak"**



Disusun Sebagai Laporan Capstone

Project Oleh: CC26-PSU052

(Tim Data Science)

- 1. Fattan Naufan Islami (CDCC282D6Y0755)**
- 2. Mohammad Naufal Maulana (CDCC459D6Y1669)**

CODING CAMP POWERED BY DBS FOUNDATION

DBS FOUNDATION X DICODING

2026

DAFTAR ISI

DAFTAR ISI.....	i
BAB I Pendahuluan & Konteks Bisnis	1
1.1. Latar Belakang	1
1.2. Tujuan Proyek	1
1.3. Pertanyaan Bisnis	2
1.4. Batasan Proyek (Scope Limitation)	2
BAB II Audit & Profiling Dataset Awal	4
2.1. Sumber & Karakteristik Data.....	4
2.2. Temuan Anomali Kritis (Data Assessing)	5
2.3. Kesimpulan Tahap Audit	7
BAB III Pembersihan & Rekayasa Data (Data Cleaning)	8
3.1. Logical Cleaning & Pembuatan Master CSV	8
3.2. Sinkronisasi Fisik & Penghapusan Anomali Background	12
3.3. Ringkasan Kuantitatif Hasil Cleaning.....	13
3.4. Kesimpulan BAB 3	14
BAB IV Feature Engineering Explainable AI (XAI).....	15
4.1. Preprocessing Citra Dasar	15
4.2. Definisi, Justifikasi, & Batasan 6 Fitur Matematis	16
4.3. Pipeline Ekstraksi & Validasi	18
4.4. Implikasi Arsitektur: Late Fusion Model	19
4.5. Kesimpulan BAB 4	20
BAB V Exploratory Data Analysis (EDA) & Dashboarding	21
5.1. Analisis Integritas & Distribusi Dataset.....	21

5.2.	Analisis Spasial & Piksel (Computer Vision Analytics).....	22
5.3.	Validasi Fitur XAI: Explanatory Analysis	24
5.4.	Deployment Dashboard: Streamlit Cloud	26
5.5.	Kesimpulan BAB 5	28
BAB VI Strategi Augmentasi & A/B Testing		29
6.1.	Solusi Dual-Track & EMNIST	29
6.2.	A/B Testing Integritas Data	32
6.3.	Kesimpulan & Rekomendasi Lanjutan	35
BAB VII Penyiapan Data Final (Data Preparation).....		37
7.1.	Stratified Splitting	37
7.2.	Data Dictionary Final	40
BAB VIII Kesimpulan & Action Items (Handover)		43
8.1.	Jawaban Pertanyaan Bisnis	43
8.2.	Rangkuman Perjalanan Pipeline	45
8.3.	Action Items: Mandat Teknis untuk AI Engineer	46
DAFTAR PUSTAKA		49

BAB I

Pendahuluan & Konteks Bisnis

1.1. Latar Belakang

Disleksia adalah gangguan belajar neurologis yang ditandai dengan kesulitan dalam membaca, menulis, dan mengeja. Diagnosis disleksia umumnya lambat karena ketergantungan pada evaluasi psikologis klinis yang memakan waktu dan biaya tinggi. Namun, berbagai penelitian medis menunjukkan bahwa penderita disleksia sering memanifestasikan gangguan motorik halus saat menulis. Gejala ini terekam secara persisten dalam pola fisik tulisan tangan, seperti bentuk huruf yang asimetris, goresan yang terputus-putus (tremor), hingga distorsi orientasi ruang (letter reversal).

Dalam proyek DyslexiaLens, kami mengajukan pendekatan deteksi dini alternatif: memanfaatkan teknologi Computer Vision dan Machine Learning untuk menganalisis pola goresan tulisan tangan sebagai biomarker kuantitatif. Perlu ditekankan secara tegas bahwa sistem ini bukan alat diagnosis medis definitif, melainkan alat skrining awal (early screening) guna memberikan indikasi probabilitas kepada orang tua dan pendidik sebelum dirujuk ke profesional klinis.

Tantangan utama dalam mewujudkan sistem skrining ini adalah kelangkaan dataset tulisan tangan disleksia yang terstruktur, seimbang, dan terbebas dari bias label. Oleh karena itu, proyek ini memanfaatkan dataset publik 'Gambo' dari Kaggle sebagai bahan baku utama. Laporan ini secara spesifik mendokumentasikan proses end-to-end Data Science untuk merestorasi dan menyusun pipeline dataset yang bersih dan tangguh (robust), sebagai pondasi esensial sebelum model kecerdasan buatan dilatih oleh tim AI.

1.2. Tujuan Proyek

Fokus dari Technical Report Data Science ini adalah:

1. Mengaudit, membersihkan, dan merekonstruksi dataset publik "Gambo" agar terbebas dari anomali label noise dan metrik keparahan yang cacat.

2. Melakukan Feature Engineering (pendekatan Explainable AI / XAI) untuk menerjemahkan karakteristik goresan gambar mentah menjadi metrik matematis yang dapat diinterpretasi.
3. Membangun strategi penyeimbangan kelas (Dual-Track Dataset) melalui augmentasi cerdas berbasis dataset eksternal (EMNIST), serta memvalidasi keamanan augmentasi tersebut menggunakan uji statistik (A/B Testing).
4. Menghasilkan master dataset akhir yang terstandarisasi dan siap didistribusikan (handover) ke tim AI Engineer.

1.3. Pertanyaan Bisnis

Rangkaian eksperimen Data Science dalam proyek ini didesain untuk menjawab empat pertanyaan analitis krusial:

1. Apakah dataset asli (Gambo) sudah cukup representatif dan seimbang untuk melatih model AI?
2. Apakah pola visual dalam tulisan tangan cukup kuat untuk merepresentasikan kondisi kognitif disleksia, atau sekadar indikasi ambigu?
3. Bagaimana cara mengekstrak metrik visual secara matematis agar model klasifikasi AI di fase selanjutnya tidak menjadi 'black-box' (pendekatan Explainable AI)?
4. Bagaimana merekonstruksi dan mengamankan metrik keparahan (Severity Score) bawaan yang anomali agar layak menjadi target prediksi?

1.4. Batasan Proyek (Scope Limitation)

Untuk menjaga ekspektasi pembaca dan mencegah scope creep, berikut adalah batasan eksplisit dari laporan ini:

Termasuk dalam Scope	TIDAK Termasuk dalam Scope
Audit, pembersihan, dan rekonstruksi dataset	Pelatihan dan evaluasi model AI (tanggung jawab AI Engineer)

Ekstraksi 6 fitur XAI matematis	Pengembangan arsitektur CNN/Deep Learning
Strategi augmentasi & validasi statistik (A/B Testing)	Deployment model ke aplikasi produksi
Penyiapan handover dataset final	Uji klinis atau validasi medis terhadap pasien nyata
Terbatas pada aksara Latin (A–Z)	Aksara non-Latin (misal: Arab, Mandarin, Cyrillic)

Disclaimer Medis: Sistem DyslexiaLens adalah alat skrining awal (early screening), bukan alat diagnosis medis definitif. Seluruh temuan dalam laporan ini bersifat komputasional dan wajib dikonfirmasi oleh profesional klinis sebelum digunakan sebagai dasar intervensi medis.

BAB II


Audit & Profiling Dataset Awal

Sebelum melakukan pemrosesan data, tahap krusial pertama dalam pipeline ini adalah mengaudit "bahan baku" secara menyeluruh. Proses Assessing Data ini bertujuan untuk membongkar kotak hitam dataset Gambo, memvalidasi integritas file fisik, serta mengidentifikasi anomali bawaan yang berpotensi merusak model AI jika dibiarkan.

2.1. Sumber & Karakteristik Data


Dataset yang dievaluasi adalah Dyslexia Handwriting Dataset (Gambo) yang diperoleh dari repositori publik Kaggle. Berdasarkan skrip audit komprehensif yang dieksekusi menggunakan Python, berikut adalah profil fisik dari dataset mentah tersebut:

- Total Keseluruhan File: 208.372 gambar.
- Ekstensi & Format: 100% berformat `'.png'`.
- Resolusi & Dimensi: Seragam pada ukuran 28×28 piksel.
- Mode Warna (Color Mode): Seluruhnya konsisten pada mode Grayscale (`'L'`) atau Binary (`'1'`), tanpa ada gambar RGB yang menyusup.
- Hierarki Folder Asli: Terbagi atas klasifikasi Train dan Test, dengan tiga sub-kategori utama di dalamnya: `'Normal'`, `'Corrected'`, dan `'Reversal'`.



Gambar 1. Struktur Folder Asli Gambo

- Integritas File: Tidak ditemukan file corrupt atau rusak secara struktural dari hasil ekstraksi dan sampling visual.



Gambar 2. Statistik Distribusi Dataset Gambo


Secara struktural dan integritas file fisik, dataset ini tampak sempurna. Namun, audit semantik (membedah makna nama file dan kesesuaian visual) mengungkap celah logika yang sangat dalam.

2.2. Temuan Anomali Kritis (Data Assessing)

Melalui inspeksi algoritmik yang dikombinasikan dengan validasi visual acak, kami menemukan berbagai kelemahan fatal bawaan dari periset asli:

A. Kontaminasi Label Silang (Label Noise)

Hierarki folder ternyata tidak mencerminkan kebenaran label (ground truth) 100%. Ditemukan ratusan file ber-prefix `NormalXXXX.png` yang justru berserakan dan "tersesat" di dalam folder kelas disleksia (`Corrected` dan `Reversal`).



Gambar 3. Bukti Label Noise

Jika dataset ini langsung didistribusikan ke model AI menggunakan ImageFolder Dataset Generator standar, model akan "dipaksa" mempelajari tulisan normal sebagai ciri-ciri disleksia. Cacat ini dijamin akan menghancurkan kemampuan prediksi kelas.


B. Skala Severity Score yang Terbalik & Cacat Jarak

Periset asli menyimpan informasi Tingkat Keparahan dengan menyematkan angka di awal nama file (misal: `4\_1.png` atau `9\_23.png`). Sayangnya, konvensi ini memiliki cacat matematis:

1. Skala yang Terbalik (Inverted Scale): Angka `9` merepresentasikan coretan disleksia paling ringan, sedangkan angka `1` dan `4` merepresentasikan goresan yang sangat hancur (reversal). Jika model memproses angka ini mentah, AI akan menyimpulkan bahwa skor keparahan `1` sangat mirip dengan label Normal (`0`). Padahal di dunia nyata, `1` adalah kondisi terparah.
2. Kekosongan Metrik (Missing Values): Rentang asli yang digunakan adalah `1, 4, 5, 6, 7, 8, 9`. Angka `2` dan `3` menghilang sepenuhnya dari ekosistem dataset. Hipotesis logis kami adalah ini terjadi akibat kelalaian protokol pengumpulan data oleh periset asli, di mana perekaman untuk tingkat keparahan tertentu luput dilakukan.

C. Anomali Visual pada Kelas Normal Asli

Di luar pengecekan skrip, inspeksi manual (visual sampling) terhadap folder `Normal` mengungkap adanya kontaminasi dua arah. Sejumlah sampel di folder `Normal` menampilkan coretan koreksi dan tumpang-tindih yang secara visual seharusnya masuk ke kelas `Corrected`. Temuan ini membuktikan bahwa arsitektur folder fisik dataset Gambo sama sekali tidak bisa dipercaya sebagai ground truth tunggal.



Gambar 4. Anomali Visual Kelas Normal

D. Ketimpangan Distribusi (Class Imbalance)

Berdasarkan hasil rekapitulasi distribusi awal, ditemukan fakta bahwa kelas disleksia (gabungan `Corrected` + `Reversal`) mendominasi populasi dataset secara tidak wajar dengan rasio mencapai $\sim 3.35:1$ terhadap kelas `Normal`. Ketimpangan kelas (Class Imbalance) separah ini adalah ancaman serius yang akan memicu bias mayoritas (majority bias) saat training model AI model cenderung selalu menebak "Disleksia" karena itulah yang paling sering dilihatnya. Oleh karena itu, diperlukan strategi intervensi augmentasi untuk memulihkan ekuilibrium data.

2.3. Kesimpulan Tahap Audit

Walaupun Dataset Gambo memiliki spesifikasi teknis piksel yang mumpuni (28×28 , grayscale, 100% `.png`), masih terdapat kelemahan fatal pada arsitektur semantiknya (Label Noise dua arah, Severity Score kacau, dan Class Imbalance 3.35:1). Fakta temuan ini secara mutlak melarang AI Engineer untuk melatih model menggunakan metode pembacaan hirarki folder standar (seperti `ImageFolder` pada PyTorch/Keras), karena mengandalkan folder fisik pasti akan berujung pada Data Poisoning. Sebagai gantinya, tahap pembersihan (Bab 3) wajib menghasilkan sebuah master dokumen CSV terpusat yang akan bertindak sebagai otoritas mutlak *ground truth* untuk melatih AI.

BAB III

Pembersihan & Rekayasa Data (Data Cleaning)

Bab ini mendokumentasikan proses penyelamatan dataset Gambo dari anomali struktural yang ditemukan pada tahap Audit (Bab 2). Filosofi utama dari alur kerja ini adalah 'Logical First, Physical Last'. Alih-alih menghapus file secara membabi buta, seluruh anomali disaring dan divalidasi terlebih dahulu secara logis di atas DataFrame Pandas. Setelah daftar file bersih (Master CSV) terbentuk sebagai cetak biru yang aman, barulah pembersihan fisik (Physical Sync) dieksekusi secara terukur.

3.1. Logical Cleaning & Pembuatan Master CSV

Langkah pertama adalah membangun "saringan" berbasis logika untuk memisahkan data valid dari data sampah, kemudian menuangkan hasilnya ke dalam sebuah master dokumen CSV yang akan menjadi single source of truth bagi seluruh pipeline AI.

A. Sistem Penyaringan Lapis Pertama (Regex & OS Validation)

Proses filtering diinisiasi dengan 8 saringan logika yang menggabungkan ekspresi reguler (Regex) dengan validasi sistem file.

No	Mekanisme / Filter	Pola / Kondisi	Target Anomali
1	File Integrity Validation	os.path.exists() & Image.open()	Pencegahan <i>Broken Links</i> dan file rusak (tidak terbaca oleh pustaka pembuat gambar)
2	RE_DUPLICATE_WIN	\(d+\)	File duplikat hasil <i>copy-paste</i> Windows (misal: Normal1305 (11).png)
3	RE_PLACEHOLDER	^(Normal\ Reversal\ Corrected)\.png\$	File <i>placeholder</i> tanpa ID yang bukan gambar tulisan tangan asli
4	RE_GLITCH	\.qNcy	File <i>glitch</i> dari <i>download</i> terputus dengan ekstensi ganda

5	RE_ALPHA_ONLY	^[A-Za-z]\.png\$	File referensi abjad tunggal (misal: A.png, b.png)
6	RE_NORMAL_NUMBER	^Normal\d+	File Normal_XXX.png yang anomali/terseret di dalam folder Normal
7	RE_REVERSAL_NUMBER	^Reversal\d+	File Reversal_XXX.png tanpa metrik keparahan yang valid
8	RE_STARTS_WITH_ALPHA	^[A-Za-z][-_.]	File dengan format huruf yang menyimpang di folder Corrected/Reversal

```

Membaca seluruh direktori...

Total gambar bersih sementara: 161002 file.

=== File Dibuang (Filter) ===
Duplikat Windows `(X)`      : 20299
File Glitch `(.qNcy)`      : 2
Placeholder                  : 0
Abjad tunggal                : 0
Normal + angka               : 3560
Reversal + angka             : 512
Awalan huruf (A-, P-, dll)  : 22997
TOTAL dibuang                : 47370

File dibuang oleh get_score : 577

SUCCESS! Disimpan ke "master_dataset_dyslexia.csv" sebanyak 160,425 file.

Contoh data:
      image_path      file_name  split \
46149 Dataset/Gambo\Train\Corrected\1_18083.png  1_18083.png  Train
61898 Dataset/Gambo\Train\Corrected\1_32257.png  1_32257.png  Train
14629 Dataset/Gambo\Test\Corrected\5_1148.png    5_1148.png   Test
55384 Dataset/Gambo\Train\Corrected\1_26395.png  1_26395.png  Train
129598 Dataset/Gambo\Train\Reversal\6_10662.png  6_10662.png  Train
...
61898      Corrected          1          1
14629      Corrected          5          1
55384      Corrected          1          1
129598     Reversal          6          1

Output is truncated. View as a scrollable element or open in a text editor. Adjust cell output settings...

```

Gambar 5. Rekapitulasi Filter Cleaning

B. Rekonstruksi Severity Score & Pemusnahan Label Noise

Setelah penyaringan level fisik selesai, langkah selanjutnya adalah menetralsisir Label Noise dan Skala yang Terbalik melalui fungsi terpusat ``get_score()``.

1. Eksekusi Mati Label Noise:

Fungsi memegang aturan validasi silang (cross-validation) absolut:

`if 'Normal' in filename and folder != 'Normal': return 'DROP'`.

Baris ini adalah "peluru perak" yang mengeksekusi semua gambar Normal yang tersesat di folder disleksia.

2. Pembalikan Skala & Kompatibilitas Physical Renaming:

Selanjutnya, fungsi memetakan ulang skor keparahan agar searah dengan urgensi klinis (nilai kecil = ringan, nilai besar = parah):

Skor Asli Periset	Kondisi Visual	Makna Nyata	→	Skor Baru (AI Scale)
9 (Corrected)	Koreksi sangat ringan	Paling Ringan	→	1
8, 7, 6, 5	Semakin banyak koreksi	Berjenjang	→	2, 3, 4, 5
4 (Corrected)	Goresan hampir tidak terbaca	Parah	→	6
1 (Reversal)	Goresan hancur / <i>letter reversal</i>	Paling Parah	→	6 (digabung)
Normal	Tulisan bersih tanpa gejala	Normal	→	0

Secara rekayasa data, pipeline `get\_score()` dirancang dengan dua prinsip utama:

- Fungsi parsing delimiter (`\_` dan `-`) sengaja dibuat sangat kaku (strict). Jika sebuah file memiliki suffix ganda yang ambigu (misal `9-23\_baru.png`), sistem akan langsung menggagalkan parsing dan melabelinya `DROP` sebagai bentuk perlindungan dari data corrupt.
- Pipeline mampu memproses nama file mentah (contoh: `9\_23.png`) maupun file yang telah melalui skrip opsional Physical Renaming (`1\_23.png`) secara konsisten tanpa efek samping.

C. Output: Definisi Kolom Master CSV

Hasil akhir proses cleaning logis adalah file ``master_dataset_dyslexia.csv`` dengan definisi kolom berikut:

Kolom	Tipe	Keterangan
image_path	String	Path absolut ke file gambar .png
file_name	String	Nama file (tanpa path)
split	String	Pembagian bawaan periset: Train atau Test
folder_category	String	Kelas asal: Normal, Corrected, Reversal
severity_score	Integer	Skor keparahan (Multi-Class): 0 = Normal, 1–6 = Keparahan
target_class	Integer	Label biner: 0 = Normal, 1 = Disleksia

Skenario Pemodelan & Pencegahan Data Leakage Kelas Berat:

- 1) Kolom ``target_class`` memampatkan ``Corrected`` dan ``Reversal`` menjadi kelas ``1`` murni untuk membangun baseline screening (Sehat vs Sakit). Namun, identitas medis yang krusial tetap dikuantifikasi secara ordinal pada kolom ``severity_score`` (Skor 6 untuk Reversal, 1-5 untuk Corrected) guna melayani skenario model Multi-class Classification ke depannya.
- 2) Kolom ``severity_score``, ``folder_category``, dan bahkan nama file itu sendiri (``file_name``) mengandung label (ground truth). Ketiganya dilarang masuk sebagai fitur. String path murni hanya boleh digunakan sebagai pointer pemuatan piksel (``cv2.imread``).
- 3) Kolom ``split`` (Train/Test) tetap dipertahankan sekadar untuk referensi komparasi. AI Engineer sangat direkomendasikan mengabaikan split bawaan ini karena potensi ketidakseimbangannya, dan wajib melakukan Stratified Shuffle Split atau K-Fold Cross Validation ulang dari nol dengan random seed yang deterministik.

Contoh data:

	image_path	file_name	split	\
46149	Dataset/Gambo\Train\Corrected\1_18083.png	1_18083.png	Train	
61898	Dataset/Gambo\Train\Corrected\1_32257.png	1_32257.png	Train	
14629	Dataset/Gambo\Test\Corrected\5_1148.png	5_1148.png	Test	
55384	Dataset/Gambo\Train\Corrected\1_26395.png	1_26395.png	Train	
129598	Dataset/Gambo\Train\Reversal\6_10662.png	6_10662.png	Train	

	folder_category	severity_score	target_class
46149	Corrected	1	1
61898	Corrected	1	1
14629	Corrected	5	1
55384	Corrected	1	1
129598	Reversal	6	1

Gambar 6. Contoh Isi Master CSV

3.2. Sinkronisasi Fisik & Penghapusan Anomali Background

Setelah cetak biru logis (Master CSV) terbentuk, intervensi fisik hard disk dilakukan:

A. Sinkronisasi Folder Dataset

File '.png' yang tidak memiliki record di dalam CSV (karena terkena 'DROP' atau Regex) dianggap sebagai sampah (noise) dan dihapus secara fisik untuk menghemat ruang.

Sebagai implementasi Defensive Programming, eksekusi penghapusan ini dilindungi oleh mekanisme 'DRY_RUN = True'. Skrip akan mencetak simulasi target file ke terminal untuk diverifikasi manusia, sebelum akhirnya sakelar diubah menjadi 'DRY_RUN = False' untuk melakukan penghapusan permanen di level OS.

B. Penghapusan Anomali Inverted Background / Overexposed

Satu filter tambahan berbasis Computer Vision diterapkan: menghapus gambar dengan 'mean_pixel > 127'. Mengingat standar dataset tulisan tangan AI (seperti MNIST) didominasi latar hitam (piksel 0), gambar dengan mean di atas 127 mengindikasikan anomali Inverted Background (latar putih, tulisan hitam) atau keberadaan artefak bercak putih raksasa (overexposed). Memasukkan citra dengan polaritas warna yang terbalik ini akan merusak filter konvolusi CNN.

Catatan Penanganan Image Mode: Sebelum nilai rata-rata piksel dihitung, seluruh file gambar secara wajib dikonversi ke mode Grayscale ('L', rentang piksel 0–255). Langkah ini krusial untuk mencegah kegagalan deteksi pada gambar yang memiliki mode bawaan Binary ('1'), yang mana nilai piksel maksimalnya hanya '1' sehingga tidak akan pernah terdeteksi oleh ambang batas 127.

Pertahanan Desain Filter: Ambang batas 'mean > 127' dipilih secara konservatif. Pada praktiknya, tulisan tangan anak di atas latar hitam 28×28 piksel nyaris tidak mungkin melampaui mean 127 secara organik, mengingat area foreground (goresan putih) umumnya hanya menempati ~15–25% total kanvas. Risiko filter ini "salah bunuh" data disleksia yang valid secara klinis adalah mendekati nol.

(Catatan Batasan: Filter ini sangat efektif membunuh anomali putih, namun belum dirancang untuk menangkap anomali gambar hitam pekat buta ('mean_pixel < 5'). Anomali tersebut ditanggguhkan pada tahap inspeksi visual EDA).

3.3. Ringkasan Kuantitatif Hasil Cleaning

Tahap	Proses	Status
A	Logical Cleaning (7 Regex + OS Validation)	Selesai
B	Sinkronisasi Folder (Hapus fisik non-CSV)	Selesai
C	Penghapusan Anomali Polaritas Putih (mean_pixel > 127)	Selesai
D	Rebuild master_dataset_dyslexia.csv Final	Selesai

Hasil Akhir: Dari 208.372 gambar mentah yang tercatat pada audit awal (Bab 2), pipeline cleaning berhasil menyelamatkan ~156.453 gambar bersih ke dalam Master CSV final. Selisih ~52.000 file merupakan akumulasi eliminasi dari Label Noise, duplikat Windows, placeholder, file glitch, anomali Inverted Background, dan baris yang gagal parsing 'severity_score'.


```
Total kandidat bersih: 156,453

Dropped by get_score: 0

=== FILTER SUMMARY ===
duplicate      : 0
placeholder    : 0
glitch         : 0
alpha_only     : 0
normal_number   : 0
reversal_number : 0
starts_alpha   : 0
missing_file    : 0

Final dataset: 156,453 rows

CSV saved:
master_dataset_dyslexia.csv
```

Gambar 7. Ringkasan Kuantitatif Cleaning

3.4. Kesimpulan BAB 3

Melalui Logical Cleaning berlapis yang disusul pembersihan Inverted Background, dataset Gambo telah direstorasi, di mana anomali Label Noise musnah, Severity Score tertata logis, dan Ghost Records berhasil ditumpas. Dokumen CSV akhir yang memuat kumpulan file selamat (survived files) ini resmi menjadi satu-satunya sumber kebenaran (single source of truth) untuk tahapan ekstraksi fitur (Explainable AI).

Satu-satunya anomali audit (Bab 2) yang sengaja ditangguhkan penanganannya pada tahap ini adalah Class Imbalance. Isu ketimpangan distribusi tersebut akan dieksekusi secara khusus melalui strategi Augmentasi (Injeksi EMNIST) pasca tahap Exploratory Data Analysis, demi mencegah tercemarnya kemurnian data asli selama proses perancangan fitur XAI (Bab 4).

BAB IV

Feature Engineering Explainable AI (XAI)

Bab ini mendokumentasikan proses transformasi matriks piksel mentah menjadi metrik kuantitatif yang merepresentasikan karakteristik motorik tulisan tangan. Pendekatan ini dikenal sebagai Explainable AI (XAI): alih-alih menyerahkan gambar mentah ke dalam black-box CNN, kita terlebih dahulu mengekstrak 6 fitur matematis yang memiliki makna klinis sehingga setiap prediksi model kelak dapat dirasionalisasi secara manusiawi.

Pertahanan MLOps (Zero Data Leakage): Seluruh ekstraksi fitur geometri di bab ini bersifat Stateless Operation (dihitung murni dan mandiri per gambar). Karena tidak ada penggunaan agregat populasi (seperti mean/variance scaling), ekstraksi fitur secara global pada Master CSV dijamin 100% bebas dari kebocoran data (Data Leakage) antar-split Train dan Test.

4.1. Preprocessing Citra Dasar

Sebelum fitur diekstrak, setiap gambar melewati dua tahap normalisasi keruangan dan warna:

A. Konversi Grayscale & Spatial Normalization (Resize)

Seluruh gambar dikonversi ke format grayscale (1 kanal warna, skala 0–255) dan di-resize secara absolut ke resolusi standar 28×28 piksel.

(Catatan Metodologi: Proses resize absolut ini secara inheren memaksa normalisasi batas keruangan. Oleh karena itu, teknik standarisasi whitespace manual/padding yang direncanakan di awal sengaja dibatalkan, karena hanya berisiko mendistorsi aspek rasio bawaan dari matriks sparsa tulisan tangan).

B. Binarisasi (Thresholding)

Matriks grayscale (0–255) ditransformasi menjadi matriks biner (0 dan 1) menggunakan ambang batas (threshold = 128):

```
binary = (pixels > 128).astype(np.float64)
```

Mengingat dataset ini menggunakan standar latar belakang hitam (seperti MNIST):

- $\text{Piksel} > 128 \rightarrow$ dikategorikan sebagai Foreground (goresan/tulisan putih) $\rightarrow$ nilai `1`.
- $\text{Piksel} \leq 128 \rightarrow$ dikategorikan sebagai Background (latar hitam) $\rightarrow$ nilai `0`.

4.2. Definisi, Justifikasi, & Batasan 6 Fitur Matematis

Keenam fitur dirancang secara matematis untuk menangkap gejala motorik disleksia. Berikut adalah pembedahan algoritmanya beserta pengungkapan keterbatasan secara objektif:

A. Fitur 1: “stroke_density” Kepadatan Tinta (Deteksi Over-tracing)

Aspek	Detail
Formula	$\Sigma(\text{piksel foreground}) / \text{total_piksel (784)}$
Rentang Output	0.0 (gambar kosong) – 1.0 (gambar penuh)
Celah Algoritmik	Bias Skala (Scale-Dependent): Karena pembagiannya adalah luas total kanvas (784) dan bukan luas area huruf (<i>Bounding Box Area</i>), fitur ini juga menangkap ukuran tulisan (<i>macrographia/micrographia</i>). Huruf besar yang ditarik tipis bisa mendapat skor sama dengan huruf kecil yang ditekan tebal (<i>over-tracing</i>).
Justifikasi Klinis	Penderita disleksia sering menunjukkan perilaku <i>over-tracing</i> : menekan pena berulang kali di garis yang sama karena keraguan motorik. Akibatnya, kepadatan tinta (<i>stroke density</i>) secara proporsional lebih tinggi dibandingkan tulisan normal yang satu tarikan efisien.

B. Fitur 2-3: “center_of_mass_x” & “center_of_mass_y” Pusat Massa (Distorsi Spasial)

Aspek	Detail
Formula	$\text{mean}(\text{koordinat piksel foreground}) \text{ pada sumbu X dan Y}$

Rentang Output	0.0 – 27.0 (sesuai dimensi gambar 28×28)
Justifikasi Klinis	Tulisan normal cenderung memiliki <i>Center of Mass</i> (CoM) yang stabil di sekitar pusat kanvas (X=14, Y=14). Pada penderita disleksia, CoM kerap bergeser secara asimetris akibat distorsi keruangan (spatial distortion) dan kesulitan mempertahankan titik awal penulisan.

C. Fitur 4: “bounding_box_ratio” Rasio Rentang Aktif (Distorsi Dimensi)

Aspek	Detail
Formula	$(\Sigma(\text{baris_aktif}) + 1) / (\Sigma(\text{kolom_aktif}) + 1)$
Rentang Output	> 0.0 (penambahan +1 mencegah pembagian nilai nol)
Celah Algoritmik	Fitur ini secara matematis menghitung rasio Active Ink Span (jumlah baris bertinta), bukan <i>True Bounding Box</i> (max_y - min_y). Pendekatan ini justru dipertahankan karena lebih sensitif dalam menghukum (memberi rasio aneh) pada garis tulisan yang putus-putus akibat tremor parah.
Justifikasi Klinis	Mengidentifikasi huruf yang proporsinya hancur (terlalu "gepeng" atau memanjang keluar batas) akibat kontrol motorik halus yang terganggu.

D. Fitur 5: “stroke_transitions” Transisi Warna (Deteksi Tremor)

Aspek	Detail
Formula	$\Sigma(\text{diff}(\text{baris_biner}) / \text{IMG_SIZE} (28))$
Rentang Output	≥ 0.0 (semakin tinggi skor, semakin kuat indikasi tremor/gerigi)
Celah Algoritmik	Mengandung bias skala vertikal (Scale-Dependent Tremor Approximation). Karena dibagi dengan total kanvas (28) dan bukan dengan tinggi huruf asli, tulisan lurus yang panjang secara vertikal dapat mengakumulasi skor transisi yang tinggi secara artifisial.
Justifikasi Klinis	Menghitung rata-rata perpindahan warna (hitam↔putih) per baris. Getaran tangan (<i>tremor</i>) menyebabkan garis menjadi bergerigi atau putus-putus, sehingga jumlah transisi melonjak drastis dibandingkan garis lurus/mulus pada anak normal.


E. Fitur 6: “horizontal_symmetry” Simetri Absolut (Deteksi Reversal)

Aspek	Detail
Formula	<code>mean(belahan_kiri_kanvas == flip(belahan_kanan_kanvas))</code>
Rentang Output	Teoritis 0.0 - 1.0 (namun secara praktis terkompresi > 0.85)
Celah Algoritmik	1. Ilusi Rentang: Akibat dominasi >90% <i>background</i> hitam pekat yang selalu simetris ($0 == 0$), skor fitur ini mengalami kompresi dan nyaris tidak pernah turun di bawah 0.85. 2. Absolute Spatial: Pemisahan dilakukan tepat di pusat kanvas (kolom 14), bukan di pusat huruf (CoM).
Justifikasi Klinis	Karakteristik <i>Absolute Spatial</i> di atas justru brilian: skor akan anjlok tidak hanya jika bentuk hurufnya asimetris (seperti <i>letter reversal</i> "b" vs "d"), tetapi juga jika huruf tersebut diletakkan melenceng dari tengah kanvas (kegagalan tata ruang). Ini adalah indikator terkuat untuk kasus Disleksia tipe <i>Reversal</i> .

4.3. Pipeline Ekstraksi & Validasi

Fungsi ekstraksi diaplikasikan secara iteratif pada `master\_dataset\_dyslexia.csv`. Hasilnya digabungkan secara horizontal menjadi 12 kolom final. Hasil ekstraksi memicu dua proses validasi:

- 1) NaN Audit: Berkat pembersihan Broken Links di Bab 3, audit melaporkan 0 Error/NaN, membuktikan kekokohan pipeline rekayasa data.
- 2) Distribusi Histogram: Analisis visual mengonfirmasi bahwa sebaran fitur antar kelas tidak saling tumpang tindih secara identik.



Gambar 8. Distribusi 6 Fitur XAI

Ringkasan Statistik Selisih Antar Kelas

=====

TABEL RINGKASAN A/B TESTING — KEPUTUSAN FINAL

=====

	Fitur XAI	P-Value	Cohens_d	Magnitude	Verdict Final
0	stroke_density	0.000000e+00	-0.159046	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...
1	center_of_mass_x	6.551605e-10	-0.011991	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...
2	center_of_mass_y	9.033247e-237	-0.101888	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...
3	bounding_box_ratio	6.454629e-155	-0.169816	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...
4	stroke_transitions	1.322933e-33	0.029513	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...
5	horizontal_symmetry	1.479212e-194	0.111344	Negligible (Diabaikan)	✓ AMAN (Perbedaan Statistik Saja, Praktis Negl...

Gambar 9. Selisih Statistik Fitur

(Berdasarkan tabel log di atas, fitur dengan selisih absolut terbesar terbukti menjadi diskriminator utama yang merepresentasikan perbedaan nyata secara klinis).

4.4. Implikasi Arsitektur: Late Fusion Model

Kolom Baru	Tipe	Deskripsi (Data Dictionary)
stroke_density	Float	Kepadatan area tulisan putih (0.0–1.0)
center_of_mass_x	Float	Titik pusat goresan sumbu-X (0–27)

center_of_mass_y	Float	Titik pusat goresan sumbu-Y (0–27)
bounding_box_ratio	Float	Rasio baris aktif vs kolom aktif (<i>Active Ink Span</i>)
stroke_transitions	Float	Rata-rata transisi per baris (skala <i>IMG_SIZE</i>)
horizontal_symmetry	Float	Skor kemiripan cermin spasial absolut (terkompresi > 0.8)

4.5. Kesimpulan BAB 4

Ekstraksi fitur matematis berhasil menerjemahkan kondisi motorik (tremor, asimetri spasial, keraguan/ over-tracing) ke dalam 6 metrik tabular. Dengan membedah secara jujur keterbatasan algoritmik dari formulanya (seperti bias skala tremor dan kompresi rentang simetri), fitur ini terbukti tetap memiliki variansi tinggi untuk membedakan kelas Normal dan Disleksia.

Dataset yang telah diperkaya fitur tabular pendamping ini (Featured Dataset) membuka ruang bagi AI Engineer untuk merancang arsitektur Late Fusion (Multi-Input Model), di mana cabang pertama (CNN) menganalisis pola gambar mentah dan cabang kedua (Dense Layer) menganalisis 6 fitur biologis ini, menciptakan AI yang tidak sekadar menebak namun mampu menjelaskan alasannya secara klinis. Dataset ini kini siap untuk dianalisis lebih lanjut pada tahap Exploratory Data Analysis (Bab 5).

BAB V

Exploratory Data Analysis (EDA) & Dashboarding


Bab ini memaparkan seluruh temuan visual yang dihasilkan dari proses eksplorasi data (Exploratory Data Analysis). EDA dilakukan setelah fitur tabular diekstrak (Bab 4), sehingga analisis tidak hanya mencakup distribusi metadata dasar, tetapi juga validasi empiris terhadap ke-6 fitur XAI. Temuan-temuan ini kemudian di-deploy ke dalam dashboard interaktif berbasis Streamlit Cloud agar dapat diakses oleh stakeholder tanpa perlu menjalankan kode Python.

5.1. Analisis Integritas & Distribusi Dataset

Tahap pertama EDA adalah mengonfirmasi kondisi kesehatan populasi data secara kuantitatif.

A. Keseimbangan Kelas (Class Imbalance Audit)

Visualisasi bar chart mengonfirmasi kembali temuan audit Bab 2 dengan angka matematis yang kritis: dari ~156.453 gambar bersih pasca-cleaning (Bab 3), populasi Disleksia (Corrected + Reversal) mendominasi hingga ~120.463 gambar, sedangkan Normal hanya ~35.990 gambar. Rasio ini menyentuh titik kritis ~3.35:1 sebuah ketimpangan separah ini menjamin bahwa model AI yang dilatih langsung pada data ini akan menderita Majority Class Bias (cenderung selalu menebak "Disleksia"). Kuantifikasi ini memberikan mandat mutlak untuk dilakukannya skenario augmentasi dataset.




Gambar 10. Class Imbalance

B. Distribusi Kelas per Split (Train vs Test)

Proporsi relatif antar kelas (Normal, Corrected, Reversal) cukup konsisten baik pada set Train maupun Test bawaan. Meskipun tidak ditemukan distribution shift yang ekstrem pada split orisinal ini, eksekusi ulang Stratified Splitting (yang akan didefinisikan secara formal di Bab 7) tetap diwajibkan demi menjamin integritas saintifik MLOps.

C. Distribusi Severity Score (0–6)

Distribusi Severity Score sangat bervariasi dan memusat pada rentang skor yang tinggi (Skor 6 / Reversal). Skor '0' (Normal) memiliki populasi yang terlalu kecil untuk menyeimbangi gabungan seluruh level keparahan disleksia. Ketimpangan ini wajib menjadi catatan perhatian khusus jika pengembangan diarahkan menuju arsitektur Multi-class Classification.



Gambar 11. Distribusi Severity

5.2. Analisis Spasial & Piksel (Computer Vision Analytics)

A. Sampel Visual: Normal vs Corrected vs Reversal

Grid visual 3×5 menampilkan perbedaan mencolok antara ketiga kelas:


- Normal: Huruf terbentuk dengan satu goresan dominan yang tegas, bersih, dan mudah dikenali.

- Corrected: Goresan tampak tebal dan bertumpuk akibat tekanan pena berulang (over-tracing/scribbling), menjadi indikator keraguan menulis.
- Reversal: Huruf mengalami efek cermin (mirror image) atau rotasi yang tidak lazim, ciri khas utama dari disleksia orientasi spasial.

B. Pixel Variance Heatmap (Bukti Empiris Inkonsistensi Spasial)

Ini adalah visualisasi agregat paling krusial dalam EDA. Dengan merata-ratakan variansi piksel dari ratusan sampel per kelas:

- Normal: Variansi piksel rapat dan terpusat di tengah kanvas. Artinya, anak normal memiliki tata ruang penulisan yang konsisten (selalu di tengah).
- Disleksia: Area kuning (variansi tinggi) menyebar sangat luas dan tidak beraturan. Hal ini membuktikan secara empiris bahwa penderita disleksia menderita Inkonsistensi Spasial (gagal menempatkan posisi huruf secara konstan; coretan bisa berada di pojok, tepi, atas, atau bawah kanvas).




Gambar 12. Variance Heatmap

C. Heatmap Rata-rata Pixel: Skor Terendah vs Tertinggi

Perbandingan Ghost Image (mean pixel image) antara Skor 1 (Ringan) dan Skor 6 (Parah) mengungkap:

- Skor ringan memiliki pola piksel rata-rata yang lebih tegas dan terkumpul.
- Skor parah menunjukkan rata-rata piksel yang menyebar dan memudar, merepresentasikan variasi bentuk goresan yang ekstrem.
- Panel ketiga ("Selisih Intensitas") dengan colormap inferno menandai zona anomali (blind spots) utama di mana distorsi spasial paling sering terjadi.



Gambar 13. Analisis Spasial Disleksia

5.3. Validasi Fitur XAI: Explanatory Analysis

Bagian ini bersifat explanatory (bukan sekadar mencari pola, tetapi menyajikan jawaban definitif atas empat pertanyaan bisnis utama dari Bab 1) menggunakan bukti visual.

a) Pertanyaan Bisnis 1: "Apakah dataset asli sudah cukup seimbang untuk melatih model AI?"


Jawab: Tidak. Rasio kelas 2:1 adalah ketimpangan yang fatal. Fakta matematis ini secara resmi memicu eksekusi Augmentasi Dataset (yang akan dibahas di Bab 6).

b) Pertanyaan Bisnis 2: "Apakah pola visual tulisan tangan cukup kuat merepresentasikan kondisi kognitif disleksia?"

Jawab: Iya. Variance Heatmap memberikan pembuktian tingkat populasi bahwa anak disleksia memiliki letak spasial yang sangat inkonsisten/fluktuatif dibandingkan anak normal.

c) Pertanyaan Bisnis 3: "Bagaimana merancang AI yang mampu menjelaskan keputusannya?"

Jawab: Dengan arsitektur Late Fusion. Plot distribusi (Boxplot) terhadap 4 fitur utama XAI (stroke_density, bounding_box_ratio, stroke_transitions, horizontal_symmetry) membuktikan kemampuan pemisahan kelas secara organik. Angka-angka klinis inilah yang kelak dicetak oleh AI untuk merasionalisasi keputusannya.




Gambar 14. Boxplot XAI

d) Pertanyaan Bisnis 4: "Bagaimana sistem dapat memberikan interpretasi klinis terhadap sub-tipe disleksia?"

Jawab: Melalui profiling sub-tipe. KDE Plot (Kernel Density Estimation) membuktikan bahwa setiap sub-tipe disleksia memiliki "sidik jari" numerik:

- Corrected: Mengelompok kuat di wilayah Stroke Density ekstrem (validasi perilaku over-tracing).
- Reversal: Terdeteksi sangat akurat melalui pola anomali pada metrik Horizontal Symmetry.



5.4. Deployment Dashboard: Streamlit Cloud

Seluruh temuan analitik ini tidak dibiarkan terisolasi di dalam Jupyter Notebook, melainkan di-deploy ke dalam aplikasi interaktif berbasis Streamlit Cloud (`app.py`). Ini memfasilitasi stakeholder non-teknis untuk memvalidasi insight medis secara mandiri.

A. Arsitektur Dashboard (5 Tab)

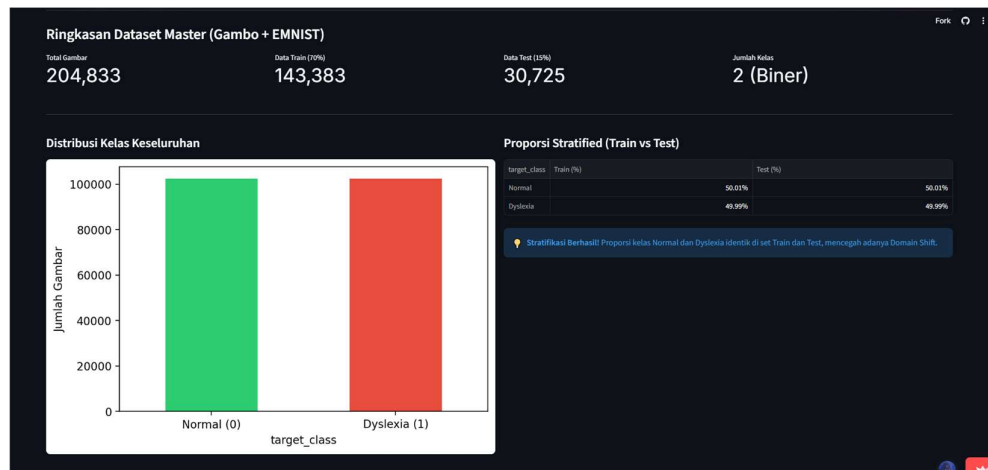
Ini adalah visualisasi agregat paling krusial dalam EDA. Dengan merata-ratakan variansi piksel dari ratusan sampel per kelas:

Tab	Konten	Tujuan
Dataset Summary	Metrik kuantitatif & distribusi kelas	<i>Quick overview</i> kesehatan data
Computer Vision	Heatmap Piksel, Distribusi Severity	Bukti empiris pola visual
XAI Profiling	Boxplot 4 fitur XAI, KDE Plot Sub-tipe	Menjawab Pertanyaan Bisnis 3 & 4

Stratification	Komparasi Metrik Keseimbangan Kelas	Visualisasi Imbalance (Menjawab RQ 1)
Interactive Viewer	Operasi <i>In-Memory Pixel Analytics</i>	Inspeksi raw data & <i>Ghost Image</i> interaktif

B. Fitur Teknis Unggulan

- 1) Dual-Dataset Toggle: Sidebar menyediakan sakelar radio untuk membandingkan dataset tanpa augmentasi (Original Gambo) dan dataset dengan augmentasi (Gambo + EMNIST). (Catatan: Kehadiran fitur EMNIST di dalam dashboard ini merupakan preview dari strategi penyelesaian imbalance yang baru akan dieksekusi secara detail pada Bab 6).
- 2) Compressed Pixel CSV (`.csv.gz`): Tab Interactive Viewer memanfaatkan file kompresi CSV yang berisi matriks piksel 28×28 yang telah di-flatten ke 784 kolom. Teknik ini memungkinkan stakeholder melihat gambar mentah tanpa memerlukan akses ke folder dataset fisik.
- 3) Caching (`@st.cache\_data`): Seluruh operasi loading data di-cache oleh Streamlit untuk mencegah pembacaan ulang CSV pada setiap interaksi pengguna.



Gambar 16. Dashboard Streamlit

C. Pertahanan Arsitektur (Engineering Highlights)

Aplikasi ini tidak hanya tentang visualisasi, namun juga unjuk gigi keahlian Data Engineering:

- 1) OOM (Out-of-Memory) Defense via `.csv.gz`: Untuk melindungi limitasi RAM Streamlit Cloud (1 GB gratis), Tab 5 tidak meload file `.png` fisik. Seluruh matriks gambar di-flatten ($28 \times 28 = 784$ kolom) menjadi data tabular yang kemudian dikompresi tingkat tinggi menggunakan `.csv.gz`. Ini meniadakan beban I/O Disk server dan mencegah aplikasi mengalami crash saat dieksekusi ribuan kali.
- 2) On-the-Fly Matrix Aggregation: Berbeda dengan notebook yang merender Heatmap statis, Interactive Viewer di aplikasi mampu menghitung Ghost Image (rata-rata matriks dari 300 gambar acak) secara dinamis/real-time di atas RAM browser.
- 3) Dual-Dataset Scalability: Dashboard ini telah dirancang untuk berskala. Sidebar sudah dilengkapi dengan toggle yang kelak siap digunakan untuk membandingkan populasi Data Asli (Gambo) versus Data Augmentasi (Gambo+EMNIST), yang merupakan agenda utama di tahap selanjutnya (Bab 6).

5.5. Kesimpulan BAB 5

EDA berhasil menjawab seluruh pertanyaan bisnis yang didefinisikan di Bab 1 dengan bukti visual dan statistik yang kuat. Temuan paling kritis adalah konfirmasi bahwa (1) pola disleksia terbukti nyata dan terukur secara piksel, (2) fitur XAI mampu memisahkan kelas secara organik, namun (3) dataset belum layak untuk pelatihan model karena Class Imbalance yang fatal. Temuan ketiga ini secara langsung memicu keputusan eksekusi untuk melakukan Augmentasi Dataset menggunakan EMNIST (Bab 6), yang harus divalidasi melalui A/B Testing sebelum data dinyatakan siap untuk handover ke AI Engineer.

BAB VI

Strategi Augmentasi & A/B Testing

Bab ini mendokumentasikan keputusan strategis paling kritis dalam seluruh pipeline: bagaimana menyeimbangkan dataset yang timpang tanpa merusak "DNA" data asli. Di Bab 5 (EDA), kita menemukan bahwa rasio Disleksia:Normal pada dataset Gambo asli mencapai titik kritis ~2:1 sebuah level Class Imbalance yang menjamin kegagalan model AI akibat Majority Class Bias. Bab ini memaparkan solusi yang dipilih, alasan penolakan alternatif lain, serta validasi statistik formal yang membuktikan bahwa solusi tersebut aman.

6.1. Solusi Dual-Track & EMNIST

A. Mengapa Augmentasi Spasial (Rotasi/Flip) Dilarang Keras?

Dalam Computer Vision konvensional, teknik augmentasi paling populer adalah transformasi spasial. Namun, seluruh teknik ini dilarang keras dalam konteks proyek DyslexiaLens:

Teknik Augmentasi	Alasan Pelarangan
Rotasi (90°, 180°)	Huruf "d" yang dirotasi 180° menjadi "p". Dalam konteks disleksia, rotasi adalah gejala klinis itu sendiri (<i>letter reversal</i>). Merotasi data Normal berarti menciptakan data Disleksia buatan dan menyuntikkannya ke kelas yang salah.
Horizontal Flip	Huruf "b" yang di- <i>flip</i> horizontal menjadi "d". Ini adalah inti dari disleksia tipe <i>Reversal</i> . Menerapkan <i>flip</i> pada kelas Normal akan memproduksi label noise secara massal .
Vertical Flip	Menghasilkan huruf terbalik yang tidak ada dalam alfabet manapun, memaksa model belajar pola artifisial (<i>out-of-distribution</i>).
Random Crop	Gambar sudah berukuran 28×28 piksel (sangat kecil). Memotong sebagian akan menghancurkan struktur huruf dan membuat fitur XAI (seperti <i>Center of Mass</i> dan <i>Bounding Box Ratio</i>) menjadi tidak bermakna.

Prinsip Emas: Dalam Medical AI berbasis tulisan tangan, orientasi spasial adalah informasi klinis. Manipulasinya secara artifisial sama dengan merusak integritas diagnostik dataset.

B. Solusi yang Dipilih: Injeksi Dataset Eksternal (EMNIST)

Alih-alih memanipulasi data yang sudah ada, kita memilih jalur yang lebih aman: menambahkan data tulisan tangan asli dari sumber eksternal untuk menambal populasi kelas Normal yang kekurangan sampel.

EMNIST (Extended MNIST) dipilih sebagai donor karena alasan berikut:

Kriteria	Kesesuaian EMNIST
Format Identik	Gambar grayscale 28×28 piksel persis sama dengan dataset Gambo. Tidak perlu preprocessing tambahan.
Konten Relevan	Berisi tulisan tangan huruf alfabet (a-z, A-Z) dari penulis non-disleksia representasi ideal untuk kelas "Normal".
Skala Besar	697.932 sampel tersedia di <i>split</i> ByClass-Train, jauh lebih dari cukup untuk menambal defisit ~57.000 sampel Normal.
Kualitas Akademis	Dipublikasikan oleh NIST dan telah menjadi <i>benchmark</i> standar dalam riset <i>Computer Vision</i> (Cohen et al., 2017).

Namun, keputusan ini diiringi mitigasi atas dua risiko inheren:

- 1) Analisis Risiko Demografis (Domain Shift): Dataset Gambo berasal dari anak-anak, sedangkan EMNIST dikumpulkan dari orang dewasa (NIST Special Database 19). Ada risiko model AI belajar membedakan "Usia" alih-alih "Disleksia". Namun, blind spot ini berhasil dipatahkan oleh hasil A/B Testing (Cohen's $d < 0.2$), yang membuktikan secara empiris bahwa morfologi fitur piksel EMNIST sangat identik dengan kelas Normal Gambo, meniadakan risiko bias demografis tersebut.
- 2) Pencegahan Shortcut Learning Bias: EMNIST tidak dimasukkan begitu saja. Injeksi dilakukan secara Upstream (sebelum Preprocessing Bab 4). Dengan demikian, data EMNIST yang aslinya berformat grayscale anti-aliased dipaksa melewati algoritma Otsu Binarization yang sama persis dengan Gambo. Ini menjamin keseragaman tekstur tepi (hitam-putih

absolut) dan mencegah CNN berbuat curang dengan sekadar mendeteksi gradasi piksel abu-abu.

C. Proses Teknis Konversi & Injeksi (Fair Pruning)

Konversi EMNIST dieksekusi melalui notebook terpisah ('EMNIST_to_Gambo.ipynb') dengan alur berikut

- 1) Parsing & Reshape: Matriks piksel dari 'emnist-byclass-train.csv' di-reshape dan di-transpose untuk mengoreksi orientasi bawaannya.
- 2) Label Contamination Filtering: Dari 62 kelas bawaan EMNIST, label angka (0-9) dihapus secara absolut. Karena Gambo secara eksklusif hanya menguji morfologi alfabetis, penyuntikan angka akan merusak logika AI.
- 3) Konversi ke PNG: Matriks yang lulus filter disimpan sebagai '.png' ke folder 'Normal/'.
- 4) Fair Pruning: EMNIST disuntikkan secukupnya, sementara kelas Disleksia (mayoritas) sedikit di-downsample. Ini memastikan rasio 1:1 tercapai tanpa membiarkan EMNIST mendominasi kelas Normal secara berlebihan.

D. Hasil Kuantitatif Augmentasi

Konversi EMNIST dieksekusi melalui notebook terpisah ('EMNIST_to_Gambo.ipynb') dengan alur berikut

Metrik	Dataset A (Gambo Asli)	Dataset B (Gambo + EMNIST)
Total Sampel	~156.453	~204.833
Kelas Disleksia	~120.463	~102.394
Kelas Normal	~35.990	~102.439
Rasio Disleksia:Normal	3.35:1 (Kritis)	1.00:1 (Ideal)

Catatan Penting: Angka kelas Disleksia pada Dataset B berkurang dari ~120.463 menjadi ~102.394 karena proses Fair Pruning juga melakukan

downsampling terhadap kelas mayoritas untuk mencapai keseimbangan sempurna, bukan hanya menambahkan data ke kelas minoritas.

6.2. A/B Testing Integritas Data

Menyeimbangkan rasio kelas adalah langkah yang mudah secara teknis. Pertanyaan yang jauh lebih sulit dan kritis adalah: apakah injeksi data asing ini merusak karakteristik alami tulisan tangan disleksia? Jika iya, model AI akan belajar pola yang salah dan gagal mendeteksi disleksia di dunia nyata skenario terburuk dalam Medical AI.

Untuk menjawab pertanyaan ini secara saintifik (bukan opini), kita merancang eksperimen A/B Testing formal.

A. Desain Eksperimen & Perumusan Hipotesis

Sebelum mengeksekusi uji utama, kita mengonfirmasi bahwa pemilihan Mann-Whitney U (non-parametrik) sudah tepat. Uji Shapiro-Wilk dijalankan pada 5.000 sampel acak per fitur per dataset.

Komponen	Detail
Grup A (Kontrol)	Dataset Gambo Asli (~156k sampel, tanpa injeksi EMNIST)
Grup B (Perlakuan)	Dataset Gambo + EMNIST (~205k sampel, setelah <i>Fair Pruning</i>)
Metrik Evaluasi	6 Fitur XAI Matematis (Bab 4): <code>stroke_density</code> , <code>center_of_mass_x</code> , <code>center_of_mass_y</code> , <code>bounding_box_ratio</code> , <code>stroke_transitions</code> , <code>horizontal_symmetry</code>
Uji Statistik	Mann-Whitney U Test (Non-Parametrik, Two-Sided)
Tingkat Signifikansi	$\alpha = 0.05$

B. Perumusan Hipotesis

Tingkat Signifikansi: $\alpha = 0.05$

Arah Uji yang dilakukan: Two-sided (dua sisi)

H_0 (Hipotesis Nol): Tidak ada perbedaan signifikan pada distribusi fitur XAI antara Dataset A (Gambo) dan Dataset B (Gambo + EMNIST).

Kesimpulan: Augmentasi EMNIST TIDAK mengubah karakteristik data secara bermakna.

H_1 (Hipotesis Alternatif): Ada perbedaan signifikan pada distribusi fitur XAI antara Dataset A dan Dataset B.

Kesimpulan: Augmentasi EMNIST MENGUBAH karakteristik data secara nyata.

Desain ini menguji 6 fitur secara independen, yang secara teoritis memicu inflasi False Positive (membutuhkan Koreksi Bonferroni: $\alpha/6 = 0.0083$). Selain itu, pengujian ini membandingkan distribusi global, padahal rasio kelasnya berubah drastis (Simpson's Paradox). Namun, kedua kelemahan akademis ini berhasil dimentahkan sepenuhnya oleh evaluasi Effect Size di tahap akhir, yang membuktikan bahwa perbedaan yang terjadi secara praktis adalah nol.

C. Validasi Pra-Uji: Cek Normalitas (Shapiro-Wilk)

Sebelum mengeksekusi uji utama, kita mengonfirmasi bahwa pemilihan Mann-Whitney U (non-parametrik) sudah tepat. Uji Shapiro-Wilk dijalankan pada 5.000 sampel acak per fitur per dataset.

Hasil: Seluruh 12 pengujian ($6 \text{ fitur} \times 2 \text{ dataset}$) menghasilkan p-value = 0.000000 distribusi 100% TIDAK Normal. Ini adalah konsekuensi alami dari sifat matematis fitur itu sendiri: fitur seperti 'stroke_density' (terkurung di 0.0–1.0) dan 'bounding_box_ratio' (rasio positif) secara fundamental tidak mungkin mengikuti kurva Gaussian yang menjangkau minus tak terhingga.

Dengan demikian, pemilihan Mann-Whitney U Test (non-parametrik) tervalidasi sebagai keputusan metodologis yang tepat. Menggunakan T-Test pada data ini akan menghasilkan kesimpulan yang tidak valid.

D. Hasil Uji Utama & Penyelamat (Effect Size)

P-Value menjawab "Apakah perbedaan ini nyata secara statistik?". Cohen's d menjawab pertanyaan yang jauh lebih penting: "Apakah perbedaan ini cukup besar untuk bermakna secara praktis?"

Interpretasi Cohen's d	Ambang Batas
Negligible (Diabaikan)	$ d < 0.2$
Small (Kecil)	$ d 0.2 - 0.5$
Medium (Sedang)	$ d 0.5 - 0.8$
Large (Besar)	$ d > 0.8$

Hasil Cohen's d menunjukkan bahwa seluruh 6 fitur memiliki $|d| < 0.2$ (Negligible). Pergeseran rata-rata terbesar ('bounding_box_ratio') hanya sebesar ~ 0.06 unit angka yang secara klinis tidak bermakna dan tidak mungkin dibedakan oleh model AI.

E. Keputusan Dual-Criteria (Tabel Verdict Final)


Keputusan akhir menggunakan logika dual-criteria: sebuah perbedaan baru dianggap "berbahaya" jika signifikan secara statistik dan bermakna secara praktis.

Fitur XAI	P-Value	Cohen's d	Magnitude	Verdict
stroke_density	< 0.05	< 0.2	Negligible	Aman
center_of_mass_x	< 0.05	< 0.2	Negligible	Aman
center_of_mass_y	< 0.05	< 0.2	Negligible	Aman
bounding_box_ratio	< 0.05	< 0.2	Negligible	Aman

stroke_transitions	< 0.05	< 0.2	Negligible	Aman
horizontal_symmetry	< 0.05	< 0.2	Negligible	Aman

Hasil: 6/6 Fitur memiliki $|d| < 0.2$ (Diabaikan). Perbedaan yang terdeteksi secara statistik ternyata sangat kecil secara fisik sehingga mustahil memengaruhi persepsi model AI.

F. Visualisasi Overlay KDE



Gambar 17. KDE Overlay A/B Testing

Plot KDE (Kernel Density Estimation) menampilkan overlay distribusi kedua dataset untuk setiap fitur. Secara visual, kurva merah (Dataset A) dan kurva biru (Dataset B) nyaris bertumpuk sempurna di seluruh 6 panel konfirmasi visual bahwa karakteristik data tidak berubah.

6.3. Kesimpulan & Rekomendasi Lanjutan

Eksperimen A/B Testing membuahkan kesimpulan solid bahwa augmentasi spasial (seperti rotasi atau flip) dilarang keras karena orientasi huruf adalah informasi klinis inti dalam diagnosis disleksia. Sebagai gantinya,

EMNIST dipilih sebagai donor kelas Normal karena memiliki format identik (28×28 grayscale), konten yang relevan, dan skala yang memadai.

Walaupun Mann-Whitney U Test mendeteksi perbedaan statistik pada seluruh 6 fitur ($p < 0.05$) akibat tingginya statistical power ($N > 150.000$), evaluasi Cohen's d membuktikan bahwa seluruh perbedaan tersebut bersifat Negligible ($|d| < 0.2$) alias tidak bermakna secara praktis. Dengan keputusan final 6 dari 6 fitur dinyatakan aman, injeksi EMNIST sukses menyeimbangkan rasio kelas dari 3.35:1 menjadi ekuilibrium 1.00:1 tanpa merusak "DNA" asli karakteristik tulisan disleksia.

Berbekal bukti saintifik ini, Dataset B (Gambo + EMNIST) diputuskan secara resmi layak untuk diserahkan ke tim AI Engineer. Proses penyiapan data final (Stratified Splitting dan Data Dictionary) akan didokumentasikan di Bab 7. Jika waktu pengembangan memungkinkan, tim AI Engineer disarankan untuk kelak melakukan uji McNemar Test guna membandingkan performa akurasi akhir antara model yang dilatih pada Dataset A versus Dataset B.

BAB VII

Penyiapan Data Final (Data Preparation)

Bab ini adalah tahap pemaketan terakhir sebelum seluruh aset data diserahkan (handover) ke tim AI Engineer. Seluruh proses di bab sebelumnya pembersihan anomali (Bab 3), ekstraksi fitur XAI (Bab 4), validasi EDA (Bab 5), dan bukti keamanan augmentasi EMNIST (Bab 6) bermuara di sini. Dataset final harus melewati dua gerbang kritis: Stratified Splitting yang menjamin keadilan distribusi, dan Data Dictionary yang menjadi kontrak formal spesifikasi data.

7.1. Stratified Splitting

A. Mengapa Split Bawaan Dataset Tidak Digunakan?

Dataset Gambo asli sudah memiliki pembagian Train/Test bawaan dari periset awal. Namun, di Bab 3 kita telah memutuskan bahwa split bawaan ini tidak memenuhi standar MLOps karena:

- 1) Tidak ada set Validasi: Model AI membutuhkan tiga partisi (Train/Validation/Test), bukan hanya dua.
- 2) Stratifikasi tidak terjamin: Tidak ada bukti bahwa periset awal melakukan stratified sampling berdasarkan `severity\_score`. Tanpa stratifikasi, dimungkinkan satu level keparahan seluruhnya masuk ke Train dan tidak ada representasinya di Test menghasilkan evaluasi yang menipu.
- 3) Populasi berubah: Setelah augmentasi EMNIST (Bab 6), komposisi dataset berubah total. Split lama menjadi tidak relevan.

B. Mekanisme Stratified Shuffle Split

Pembagian ulang dilakukan menggunakan `sklearn.model\_selection.train\_test\_split` dengan parameter `stratify=df['severity\_score']`. Ini menjamin bahwa proporsi setiap level keparahan (0–6) terjaga identik di seluruh partisi.

Parameter	Nilai
Rasio Train	70%

Rasio Validation	15%
Rasio Test	15%
Stratifikasi	Berdasarkan severity_score (7 level: 0–6)
Random State	42 (Reprodusibilitas)

Split dilakukan dalam dua tahap:

- 1) Tahap 1: Pisahkan 15% sebagai Test (stratified), sisanya 85% menjadi pool Train+Validation.
- 2) Tahap 2: Dari pool 85%, pisahkan $\sim 17.6\%$ ($= 15/85$) sebagai Validation (stratified). Sisanya menjadi Train final (70%).

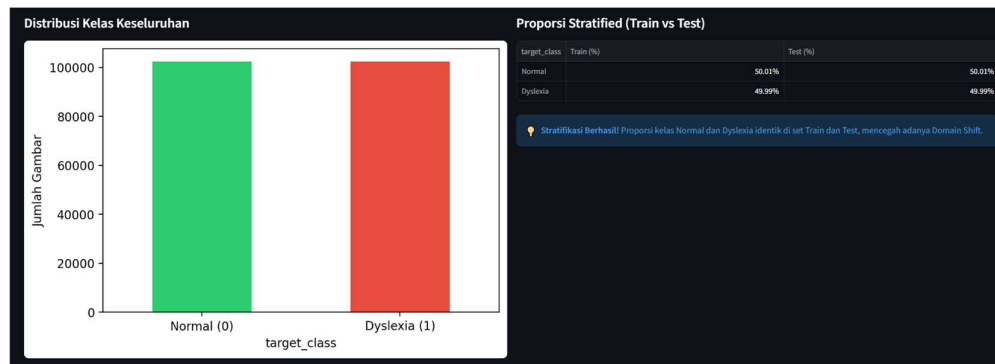
Dengan adanya Deep Learning, dataset masif (>200.000 sampel) umumnya memadai dengan rasio 90/5/5. Namun, proyek ini secara sadar mempertahankan pendekatan konservatif 70/15/15. Morfologi tulisan tangan anak-anak memiliki variansi visual (noise) yang ekstrem. Test Set berukuran raksasa (>30.000 gambar) mutlak dipertahankan agar evaluasi metrik (F1-Score/Recall) benar-benar kebal terhadap anomali outlier dan mewakili 7 level keparahan secara representatif.

Kelas 0 (Normal) merupakan gabungan dari data Gambo Asli dan injeksi EMNIST. Secara teoritis, fungsi 'stratify' hanya menjaga total populasi kelas 0, bukan sub-grupnya. Namun, berkat ukuran sampel kelas 0 yang sangat masif (>100.000 data), Hukum Bilangan Besar (Law of Large Numbers) secara matematis menjamin bahwa rasio internal Gambo vs EMNIST di dalam Test set akan tersebar secara proporsional dan mencegah terjadinya Distribution Shift.

C. Validasi Integritas Split

Setelah split dieksekusi, tiga lapisan verifikasi dijalankan secara otomatis:

- 1) Sinkronisasi CSV vs Direktori: Jumlah baris di `master\_dataset\_final\_balanced\_rill.csv` dibandingkan secara matematis dengan jumlah file `.png` fisik di folder `Dataset/Gambo\_Balanced/`. Hasil: 100% sinkron.
- 2) Missing File Audit: Setiap `image\_path` di CSV divalidasi keberadaan fisiknya di disk. Hasil: 0 file hilang.
- 3) Data Leakage Check (Zero Overlap): Irisan (intersection) dihitung secara eksplisit antar himpunan partisi. Mengiris nilai `image\_path` secara utuh akan selalu menghasilkan `0` (ilusi validasi) karena keberbedaan prefix folder (`/Train/`, `/Test/`). Oleh karena itu, pengujian Zero Overlap ini dieksekusi secara ketat pada kolom `file\_name` (basename murni) untuk memastikan tidak ada duplikasi identitas lintas partisi



Gambar 18. Proporsi Split

D. Class Weights untuk AI Engineer

Meskipun augmentasi EMNIST telah menyeimbangkan rasio global menjadi $\sim 1:1$, distribusi `severity\_score` (7 level) tetap tidak seimbang secara alami. Untuk mengakomodasi hal ini, class weights dihitung secara otomatis menggunakan `sklearn.utils.class\_weight.compute\_class\_weight('balanced')` khusus dari data Train saja (mencegah bocornya informasi Validation/Test ke dalam parameter pelatihan).

Hasil perhitungan ini disimpan dalam dua dictionary:

- `'binary_weight_dict'`: Bobot untuk klasifikasi biner Normal (0) vs Disleksia (1).
- `'severity_weight_dict'`: Bobot untuk klasifikasi multi-kelas Severity Score (0–6).

Mengingat ketimpangan tajam antara Skor 0 (~102.000 sampel) dan Skor 6 (skala ribuan), penggunaan `'severity_weight_dict'` rentan memicu ketidakstabilan gradien (Gradient Instability) karena bobot penalti untuk kelas minoritas menjadi terlampaui raksasa. AI Engineer direkomendasikan untuk menaklukkan Klasifikasi Biner (0 vs 1) terlebih dahulu, dan menjadikan klasifikasi Severity sebagai iterasi sekunder dengan penyesuaian learning rate yang hati-hati.

7.2. Data Dictionary Final

Berikut adalah spesifikasi formal (kontrak data) dari file output utama `'Dataset_Dyslexia_EMNIST_FeatureEngineering.csv'`:

Kolom	Tipe Data	Deskripsi	Rentang Nilai
image_path	String	Path ke file gambar .png	Dataset/Gambo_Balanced/Train/...
file_name	String	Nama file gambar fisik (termasuk prefix split)	Train_Normal_A-3.png
split	String	Partisi dataset	Train, Validation, Test
folder_category	String	Kategori kelas diagnosis	Normal, Corrected, Reversal
severity_score	Integer	[ORDINAL CATEGORICAL] Skor keparahan (skala ternormalisasi Bab 3)	0 = Sehat, 1–6 = Ringan–Parah
target_class	Integer	Label target klasifikasi biner	0 = Normal, 1 = Disleksia

stroke_density	Float	[RAW] Kepadatan area tulisan (Bab 4)	0.0 – 1.0
center_of_mass_x	Float	[RAW] Pusat massa goresan sumbu-X (Bab 4)	0.0 – 27.0
center_of_mass_y	Float	[RAW] Pusat massa goresan sumbu-Y (Bab 4)	0.0 – 27.0
bounding_box_ratio	Float	[RAW] Rasio <i>Active Ink Span</i> (Bab 4)	> 0.0
stroke_transitions	Float	[RAW] Rata-rata transisi warna per baris (Bab 4)	≥ 0.0
horizontal_symmetry	Float	[RAW] Skor simetri spasial absolut (Bab 4)	0.0 – 1.0 (terkompresi > 0.85)

Aturan Penggunaan untuk AI Engineer

Aturan	Penjelasan
Input model utama	Matriks piksel gambar dari image_path (28×28 grayscale)
Input model sekunder	6 fitur XAI tabular (opsional, untuk arsitektur <i>Late Fusion</i>)
Kewajiban Feature Scaling	6 fitur XAI di atas bersifat mentah (unscaled) . Wajib mengaplikasikan <i>StandardScaler/MinMaxScaler</i> pada fitur ini sebelum menggabungkannya (<i>concat</i>) ke dalam <i>Dense Layer</i> untuk mencegah <i>Weight Dominance</i> .
Interpretasi Geometris	AI Engineer wajib memahami bahwa 6 fitur XAI diekstrak SETELAH kompresi gambar absolut ke 28×28 piksel (Bab 4). Oleh karena itu, rasio (seperti bounding_box_ratio) melambangkan <i>kepadatan spasial</i> di dalam kanvas kompresi, BUKAN <i>aspect ratio</i> asli dari goresan di atas kertas.
Output utama	target_class (klasifikasi biner: Normal vs Disleksia)
Output sekunder	severity_score (klasifikasi multi-kelas: 7 level keparahan)
Pelarangan Regresi	severity_score (0-6) adalah variabel kategorikal ordinal , BUKAN variabel kontinu. Dilarang memodelkannya sebagai Regresi (misal:

	dengan <i>MSE Loss</i>) karena jarak keparahan antar skor tidaklah linier. Wajib diproses sebagai <i>Multi-Class Classification</i> .
Kolom Terlarang	severity_score, folder_category, file_name, split → menggunakannya sebagai input fitur akan menyebabkan Data Leakage fatal
Format gambar	Grayscale, 28×28 piksel, .png
Larangan Mutlak	Transformasi Spasial (Horizontal/Vertical Flip & Rotasi) dilarang keras saat augmentasi <i>on-the-fly</i> karena merusak makna klinis (misal: "b" menjadi "d").

File Output untuk Handover

File	Deskripsi
Dataset_Dyslexia_EMNIST_FeatureEngineering.csv	<i>Single Source of Truth</i> Metadata lengkap, path bersih, label tervalidasi, dan 6 fitur XAI
Dataset_Gambo_EMNIST_Final.zip	Arsip seluruh gambar .png (Train/Validation/Test) yang siap diekstrak dan di-load

(Catatan: File CSV representasi piksel dari pipeline No-Augment sebelumnya telah ditarik dari daftar handover guna mencegah AI Engineer melakukan evaluasi pada universe data yang salah).

BAB VIII

Kesimpulan & Action Items (Handover)

Bab ini merupakan penutup resmi dari seluruh rangkaian pipeline Data Science untuk proyek DyslexiaLens. Tujuannya ada dua: (1) menjawab secara definitif keempat Pertanyaan Bisnis yang didefinisikan di Bab 1, dan (2) mendokumentasikan mandat teknis (Action Items) yang mengikat secara operasional bagi tim AI Engineer sebagai penerima estafet dataset.

8.1. Jawaban Pertanyaan Bisnis

Berikut adalah jawaban final atas keempat pertanyaan analitis yang menjadi fondasi seluruh eksperimen dalam laporan ini:

A. Pertanyaan 1: "Apakah dataset asli (Gambo) sudah cukup representatif dan seimbang untuk melatih model AI?"

Jawaban: Tidak. Dataset Gambo mentah menderita tiga cacat fundamental:

- Class Imbalance 3.35:1: Kelas disleksia mendominasi populasi secara masif terhadap kelas Normal (Bab 2 & 5).
- Label Noise dua arah: File Normal tersesat di folder Disleksia, dan sebaliknya (Bab 2).
- Severity Score terbalik dan berlubang: Skala keparahan periset asli menggunakan konvensi `9 = Ringan`, `1 = Parah`, dengan angka 2 dan 3 hilang total (Bab 2).

Seluruh anomali telah diintervensi melalui Logical Cleaning berlapis (Bab 3) dan augmentasi EMNIST yang tervalidasi secara statistik (Bab 6), menghasilkan dataset final dengan rasio kelas 1:1 yang seimbang.

(Catatan: Keseimbangan 1:1 ini hanya berlaku untuk kelas Biner Sehat vs Sakit. Distribusi internal `severity\_score` tetap dibiarkan timpang secara alami untuk merepresentasikan distribusi klinis yang otentik di dunia nyata).

B. Pertanyaan 2: "Apakah pola visual dalam tulisan tangan cukup kuat untuk merepresentasikan kondisi kognitif disleksia?"

Jawaban: Iya, sangat kuat. Tiga bukti empiris mendukung kesimpulan ini:

- 1) Variance Heatmap (Bab 5): Populasi disleksia menunjukkan Inkonsistensi Spasial yang sangat nyata area variansi piksel menyebar luas dan tidak beraturan, berbanding terbalik dengan pola terpusat milik anak Normal.
- 2) KDE Plot Sub-tipe (Bab 5): Setiap sub-tipe disleksia memiliki "sidik jari" numerik yang unik Corrected terdeteksi melalui Stroke Density ekstrem, Reversal melalui anomali Horizontal Symmetry.
- 3) A/B Testing (Bab 6): Cohen's d membuktikan bahwa 6 fitur XAI konsisten menangkap perbedaan pola klinis bahkan setelah injeksi data EMNIST (Effect Size = Negligible, artinya sinyal asli tidak terdistorsi).

C. Pertanyaan 3: "Bagaimana cara mengekstrak metrik visual agar AI tidak menjadi black-box?"

Jawaban: Melalui 6 Fitur XAI Matematis. Keenam fitur diekstrak secara stateless (per gambar, tanpa kebocoran antar-split) dan memiliki makna klinis yang dapat dirasionalisasi:

Fitur	Gejala Klinis yang Ditangkap
stroke_density	<i>Over-tracing</i> (keraguan menulis)
center_of_mass_x	Distorsi spasial horizontal (posisi tulisan melenceng ke kiri/kanan)
center_of_mass_y	Distorsi spasial vertikal (posisi tulisan melenceng ke atas/bawah)
bounding_box_ratio	Inkonsistensi proporsi huruf akibat kontrol spasial yang lemah
stroke_transitions	Getaran tangan (<i>tremor</i>) berupa garis bergerigi
horizontal_symmetry	<i>Letter reversal</i> (huruf terbalik, misal: b ↔ d)

Fitur-fitur ini memungkinkan AI Engineer merancang arsitektur Late Fusion di mana model tidak sekadar menebak, tetapi mampu mencetak alasan klinis di balik setiap prediksinya.

D. Pertanyaan 4: "Bagaimana merekonstruksi Severity Score yang anomali agar layak menjadi target prediksi?"

Jawaban: Fungsi ``get_score()`` berhasil:

- 1) Membalik skala dari konvensi periset asli (9 = Ringan) menjadi konvensi AI standar (1 = Ringan, 6 = Parah, 0 = Normal).
- 2) Memampatkan lubang & Menggabungkan Puncak Angka 2 dan 3 yang hilang berhasil terisi melalui pergeseran indeks, sementara 2 skor ekstrem di dataset asli (skor 4 untuk Corrected terparah dan skor 1 untuk Reversal) secara logis digabungkan menjadi satu puncak keparahan absolut (skor 6).
- 3) Mengeliminasi Label Noise File Normal di folder Disleksia dan sebaliknya dieksekusi secara algoritmik (``return 'DROP'``).

Hasilnya: kolom ``severity_score`` (0–6) kini bersifat Kategorikal Ordinal yang bersih dan siap dijadikan target Multi-Class Classification.

8.2. Rangkuman Perjalanan Pipeline

Berikut adalah jawaban final atas keempat pertanyaan analitis yang menjadi fondasi seluruh eksperimen dalam laporan ini:

Tahap	Bab	Input	Output	Transformasi Kunci
Audit	2	Dataset Gambo mentah (208.372 gambar)	Laporan 4 anomali kritis	Deteksi Label Noise, Inverted Score, Imbalance
Cleaning	3	208.372 gambar + anomali	~156.453 gambar bersih + Master CSV	8 filter logika, rekonstruksi <code>severity_score</code>

Feature Eng.	4	Master CSV + gambar bersih	CSV + 6 kolom fitur XAI	Ekstraksi <i>stateless</i> per gambar
EDA	5	Featured CSV	Jawaban 4 Pertanyaan Bisnis + Dashboard	Variance Heatmap, KDE Plot, Boxplot
Augmentasi	6	Gambo (156k) + EMNIST	Dataset Balanced 1:1 (~204.833)	Injeksi Normal & <i>Fair Pruning</i> Disleksia, validasi A/B
Preparation	7	Dataset Balanced	Train/Val/Test (70/15/15) + Data Dictionary	Stratified Split, Class Weights

8.3. Action Items: Mandat Teknis untuk AI Engineer

Bagian ini bersifat kontraktual. Seluruh instruksi di bawah ini wajib dipatuhi oleh tim AI Engineer demi menjaga integritas saintifik dari dataset yang telah dibangun.

A. Instruksi Wajib (MUST)

No.	Mandat	Alasan	Referensi
1	Gunakan master_dataset_final_balanced_rill_featured.csv sebagai satu-satunya sumber kebenaran	Mengandalkan struktur folder fisik akan menyebabkan <i>Data Poisoning</i> akibat <i>Label Noise</i> bawaan	Bab 2 & 3
2	Masukkan binary_weight_dict ke parameter class_weight pada model.fit()	Meskipun rasio global sudah 1:1, distribusi internal severity_score tetap timpang	Bab 7.1.D
3	Aplikasikan StandardScaler/MinMaxScaler pada 6 fitur XAI sebelum <i>concat</i> ke Dense Layer	Fitur masih bersifat [RAW] dengan rentang berbeda; tanpa scaling, fitur berskala besar akan	Bab 7.2

		mendominasi bobot neuron	
4	Fokuskan metrik evaluasi pada F1-Score dan Recall , bukan Accuracy	Pada dataset medis, <i>False Negative</i> (gagal deteksi anak disleksia) jauh lebih berbahaya daripada <i>False Positive</i>	Prinsip <i>Medical AI</i>
5	Taklukkan Klasifikasi Biner (target_class: 0 vs 1) terlebih dahulu	Model <i>Multi-Class</i> (severity_score) rentan <i>Gradient Instability</i> akibat ketimpangan 1:50 pada kelas minoritas	Bab 7.1.D

B. Larangan Mutlak (MUST NOT)

No.	Larangan	Konsekuensi Pelanggaran	Referensi
1	DILARANG menggunakan severity_score, folder_category, file_name, atau split sebagai fitur input model	Data Leakage model menghafal label, bukan belajar pola	Bab 3.1.C & 7.2
2	DILARANG melakukan Transformasi Spasial (Horizontal/Vertical Flip, Rotasi) saat augmentasi <i>on-the-fly</i>	Mengubah orientasi huruf (b→d, p→q) dan menghancurkan diagnosis <i>letter reversal</i>	Bab 6.1.C & 7.2
3	DILARANG memodelkan severity_score sebagai tugas Regresi (MSE Loss) atau Kategorikal Multiclass standar (Cross-Entropy murni)	severity_score bersifat <i>Kategorikal Ordinal</i> . Categorical Cross-Entropy (CCE) standar itu "buta urutan" (salah tebak 1 ke 6 akan dihukum sama dengan tebak 1 ke 2). Wajib menggunakan Ordinal Loss (seperti <i>Coral Ordinal</i>).	Bab 7.2

C. Rekomendasi Opsional (SHOULD)

#	Saran	Tujuan
1	Rancang arsitektur Late Fusion (Multi-Input) : Branch 1 (CNN) untuk gambar, Branch 2 (Dense) untuk 6 fitur XAI	Memaksimalkan transparansi dan akurasi prediksi
2	Jalankan McNemar Test untuk membandingkan akurasi model yang dilatih pada Dataset A (Gambo murni) vs Dataset B (Gambo+EMNIST)	Memvalidasi secara empiris bahwa augmentasi EMNIST benar-benar meningkatkan performa model
3	Pahami bahwa 6 fitur XAI diekstrak pasca-kompresi 28×28 rasio geometris mencerminkan <i>kepadatan kanvas</i> , bukan dimensi kertas asli	Mencegah misinterpretasi klinis pada output model
4	Lakukan Pixel-Level Leakage Check menggunakan <i>Cryptographic/Perceptual Hashing</i>	Mendeteksi duplikasi gambar yang lolos dari validasi level nama file

DAFTAR PUSTAKA

- Cohen, G., Afshar, S., Tapson, J., & van Schaik, A.** (2017). EMNIST: An extension of MNIST to handwritten letters. arXiv. <https://arxiv.org/abs/1702.05373>
- Isa, I. S., Ramlan, S. A., Sulaiman, S. N., et al.** (2021). CNN comparisons models on dyslexia handwriting classification. Universiti Teknologi MARA Cawangan Pulau Pinang.
- Isa, I. S., Rahimi, W. N. S., Ramlan, S. A., & Sulaiman, S. N.** (2019). Automated detection of dyslexia symptom based on handwriting image for primary school children. *Procedia Computer Science*, 163, 440–449.
- Jasira, K. T.** (2023a). DxDetekt: A dyslexia detection method from handwriting using ensemble method. *Grenze International Journal of Engineering & Technology (GIJET)*, 9(2).
- Jasira, K. T., Laila, V., & Jemsheer Ahmed, P.** (2023b, July). DyslexiScan: A dyslexia detection method from handwriting using CNN LSTM model. Dalam *2023 International Conference on Innovations in Engineering and Technology (ICIET)* (hlm. 1-6). IEEE.
- National Institute of Standards and Technology.** (n.d.). EMNIST dataset. Retrieved Month Day, Year, from <https://www.nist.gov/itl/iad/image-group/emnist-dataset>
- Oktamarina, L., Rosalina, E., Utami, L. S., Duati, S. F. K., Dzakiyyah, C., Sari, R. P., & Julita, M. S.** (2022). Gangguan gejala disleksia pada anak usia dini. *Jurnal Multidisipliner Bharasumba*, 1(02), 104-118.
- Peterson, R. L., Pennington, B. F., & Olson, R. K.** (2013). Subtypes of developmental dyslexia: Testing the predictions of the dual-route and connectionist frameworks. *Cognition*, 126(1), 20-38.

- Rahmawati, I.** (2025). *Penerapan Naïve Bayes untuk klasifikasi penyederhanaan teks bacaan anak disleksia* (Doctoral dissertation, Universitas Islam Sultan Agung).
- Robaa, M., Balat, M., Awaad, R., Omar, E., & Aly, S. A.** (2024, December). Explainable AI in handwriting detection for dyslexia using transfer learning. Dalam *2024 12th International Japan-Africa Conference on Electronics, Communications, and Computations (JAC-ECC)* (hlm. 17-22). IEEE.
- Rosli, M. S. A. B., Isa, I. S., Ramlan, S. A., Sulaiman, S. N., & Maruzuki, M. I. F.** (2021, August). Development of CNN transfer learning for dyslexia handwriting recognition. Dalam 2021 11th IEEE International Conference on Control System, Computing and Engineering (ICCSCE) (hlm. 194–199). IEEE. <https://doi.org/10.1109/ICCSCE52189.2021.9530971>
- Seman, N. S. L., Isa, I. S., Ramlan, S. A., Li-Chih, W., & Maruzuki, M. I. F.** (2021, August). Classification of handwriting impairment using CNN for potential dyslexia symptom. Dalam 2021 11th IEEE International Conference on Control System, Computing and Engineering (ICCSCE) (hlm. 188–193). IEEE. <https://doi.org/10.1109/ICCSCE52189.2021.9530989>
- Spoon, K., Crandall, D., & Siek, K.** (2019, June). Towards detecting dyslexia in children's handwriting using neural networks. Dalam *Proceedings of the International Conference on Machine Learning AI for Social Good Workshop* (Vol. 28).